

Preparación de base de datos para Evidencia 2

Una vez aplicada la encuesta, deben transformar las respuestas en una **base de datos limpia, rectangular y analizable**. Esto significa que la información debe quedar organizada en filas y columnas, sin celdas combinadas, sin respuestas mezcladas y con nombres de variables claros.

La base debe poder abrirse y procesarse en **Python**.

1. Principio básico: una fila por persona encuestada

Cada fila debe representar a **una persona encuestada**.

Cada columna debe representar **una variable**.

La estructura general debe verse así:

id	genero	edad	ocupacion	genero_musical_ favorito	cancion_ 01	cancion_ 02	cancion_ 03 ...	cancion_ 30
1	Mujer	20	Estudiante	Pop	5	3	0 ...	4
2	Hombre	24	Estudiante	Rock	2	5	4 ...	0
3	No binario	21	Estudiante	Electrónica	4	0	5 ...	3

Esta forma se llama comúnmente **formato ancho**. Es útil porque permite tener en una sola tabla los datos sociodemográficos y las calificaciones de cada ítem.

2. Crear una columna de identificación

La base debe incluir una columna llamada:

id

Esta columna no debe contener nombres reales. Solo debe numerar a las personas encuestadas:

1, 2, 3, 4, 5...

Ejemplo:

id	genero	edad	ocupacion
1	Mujer	20	Estudiante
2	Hombre	21	Estudiante

id	genero	edad	ocupacion
3	Prefiero no responder	19	Estudiante

El id permite identificar cada registro sin usar datos personales directos.

3. No incluir datos personales innecesarios

La base **no debe contener**:

- Nombre.
- Correo electrónico.
- Teléfono.
- Matrícula.
- Dirección.
- Usuario de redes sociales.
- Institución específica.
- Cualquier dato que permita identificar directamente a la persona.

Si Google Forms o Microsoft Forms recopila automáticamente el correo electrónico, esa columna debe eliminarse antes del análisis.

4. Usar nombres de columnas claros y compatibles con Python

Los nombres de las columnas deben escribirse sin espacios, sin acentos y sin caracteres especiales.

Conviene usar minúsculas y guion bajo.

En lugar de:

Género musical favorito

usar:

genero_musical_favorito

En lugar de:

Califica "Bohemian Rhapsody"

usar:

cancion_01

Ejemplo recomendado:

Nombre correcto	Nombre problemático
genero	Género
edad	Edad de la persona
ocupacion	¿Cuál es tu ocupación?
genero_musical_favorito	Género musical favorito
cancion_01	Califica la canción 1
cancion_02	Califica la canción 2

Esto evita errores al trabajar con código.

5. Crear una tabla adicional con la información de las canciones

Para no perder la información de qué canción corresponde a cada columna, se recomienda crear una segunda tabla llamada, por ejemplo:

catalogo_canciones

Esa tabla debe tener esta estructura:

variable	cancion	artista	genero_cancion
cancion_01	Blinding Lights	The Weeknd	Pop
cancion_02	Bohemian Rhapsody	Queen	Rock
cancion_03	Tití me preguntó	Bad Bunny	Urbano
...	...	...	...
cancion_30	Canción 30	Artista	Género

Esta tabla es importante porque la base principal solo tendrá columnas como cancion_01, cancion_02, etc. El catálogo permite saber qué obra corresponde a cada código.

6. Codificar de manera uniforme las respuestas

Las respuestas deben escribirse siempre de la misma manera.

Por ejemplo, en la columna ocupacion, no conviene tener variaciones como:

Problema
estudiante

Problema

Estudiante
Estudiante universitario
estudio
alumno

Es mejor normalizar las categorías:

Forma normalizada

Estudiante
Empleado/a
Docente
Trabajador/a independiente
Desempleado/a
Labores de cuidado
Otra
Prefiero no responder

Lo mismo aplica para el género musical favorito.

Evitar:

Problema

reggaeton
Reguetón
reguetón
urbano
música urbana

Decidir una categoría y mantenerla igual en toda la base, por ejemplo:

Urbano / reguetón

7. Revisar que las calificaciones sean numéricas

Las 30 columnas de canciones deben contener únicamente valores numéricos:

0, 1, 2, 3, 4, 5

No deben aparecer textos como:

- “Me gusta mucho”.

- “No la conozco”.
- “Cinco”.
- “N/A”.
- “-”.

La escala debe quedar así:

Valor	Interpretación
0	No la conozco / no puedo calificarla
1	No me gusta
2	Me gusta poco
3	Me gusta moderadamente
4	Me gusta mucho
5	Me encanta

Para el análisis, es importante recordar que el 0 no representa rechazo, sino ausencia de calificación válida.

8. Separar el valor 0 de las calificaciones reales

Como el 0 significa “no conozco la canción”, no debe tratarse como una calificación baja.

Ejemplo:

Supongamos que una canción tiene estas respuestas:

Persona	Calificación
1	5
2	4
3	0
4	0
5	3

El promedio no debería calcularse así:

$$(5 + 4 + 0 + 0 + 3) / 5 = 2.4$$

Ese promedio es engañoso, porque los ceros no significan que la canción no gustó.

Lo correcto sería calcular el promedio solo con quienes sí la conocen:

$$(5 + 4 + 3) / 3 = 4.0$$

Por eso, en Python puede convenir transformar los valores 0 en valores perdidos o NA para algunos análisis.

9. Formato recomendado de la base principal

La base principal puede llamarse:

respuestas_encuesta.csv

Debe tener una estructura como esta:

i d	genero	eda d	ocupacio n	genero_musical_favo rito	cancion_ 01	cancion_ 02	cancion_ 03	cancion_ 04
1	Mujer	20	Estudiante	Pop	5	4	0	3
2	Hombre	24	Empleado /a	Rock	2	5	4	0
3	No binario Prefiero	22	Estudiante	Electrónica	4	0	5	2
4	no responder	30	Docente	Jazz	0	3	4	5

Aunque aquí solo aparecen cuatro canciones, la tabla real deberá tener las 30 columnas de canciones.

10. Formato recomendado del catálogo de canciones

La segunda tabla puede llamarse:

catalogo_canciones.csv

Ejemplo:

variable	cancion	artista	genero_cancion
cancion_01	Blinding Lights	The Weeknd	Pop
cancion_02	Bohemian Rhapsody	Queen	Rock
cancion_03	Tití me preguntó	Bad Bunny	Urbano / reguetón

variable	cancion	artista	genero_cancion
cancion_04	La llorona	Chavela Vargas	Música tradicional
cancion_05	Shape of You	Ed Sheeran	Pop

Esta tabla será útil para interpretar los resultados y presentar recomendaciones con nombre de canción y artista.

11. Guardar la base en CSV

Para usar los datos en Python o R, lo más recomendable es guardar la base en formato:

.csv

Desde Google Sheets:

Archivo → Descargar → Valores separados por comas (.csv)

Desde Excel:

Guardar como → CSV UTF-8 delimitado por comas

Es importante usar **CSV UTF-8** para evitar problemas con acentos y caracteres especiales.

12. Base en formato largo para análisis avanzado

Además del formato ancho, puede ser útil transformar la base a **formato largo**.

En formato largo, cada fila representa una calificación de una persona a una canción.

Ejemplo:

id	genero	edad	ocupacion	genero_musical_favorito	cancion	calificacion
1	Mujer	20	Estudiante	Pop	cancion_01	5
1	Mujer	20	Estudiante	Pop	cancion_02	4
1	Mujer	20	Estudiante	Pop	cancion_03	0
2	Hombre	24	Empleado/a	Rock	cancion_01	2
2	Hombre	24	Empleado/a	Rock	cancion_02	5

Este formato es útil para:

- Calcular promedios por canción.
- Analizar preferencias por género musical.
- Hacer gráficas.
- Construir modelos de recomendación.
- Comparar grupos de edad, género u ocupación.

La base original puede estar en formato ancho, pero para algunos análisis conviene convertirla a formato largo.

13. Errores frecuentes que deben evitar

Deben evitar estos problemas:

1. Usar nombres reales de personas encuestadas.
2. Dejar columnas con títulos largos de Google Forms.
3. Mezclar texto y números en las calificaciones.
4. Usar el 0 como si fuera una mala calificación.
5. Tener varias formas de escribir la misma categoría.
6. Incluir más datos personales de los solicitados.
7. Trabajar con una base que no tenga identificador.
8. Dejar celdas combinadas.
9. Usar colores como sustituto de datos.
10. No conservar el catálogo de canciones.

14. Lista de verificación para entregar la base

Antes de entregar, deben confirmar:

Requisito	Sí / No
La base tiene entre 25 y 30 respuestas	
Cada fila corresponde a una persona encuestada	
Cada columna corresponde a una variable	
Existe una columna id	
No hay nombres, correos, teléfonos ni datos identificables	
Las columnas tienen nombres claros y sin espacios	
Las 30 canciones están nombradas como cancion_01 a cancion_30	
Existe un catálogo de canciones separado	
Las calificaciones son valores de 0 a 5	
El valor 0 significa “no conozco / no puedo calificar”	
La base está guardada en CSV UTF-8	
La base puede abrirse en Python	

Requisito**Sí / No**

El nombre de la canción corresponde siempre al mismo número de canción

15. Recomendación final

La base de datos no debe parecer una encuesta copiada directamente de Google Forms. Debe ser una tabla preparada para análisis.

La diferencia es esta:

Una encuesta recoge respuestas.

Una base de datos organiza esas respuestas para analizarlas.

Para esta evidencia, una buena base de datos será aquella que permita calcular promedios, comparar preferencias por edad, género u ocupación y generar recomendaciones musicales de manera clara, ética y reproducible.